Science des données - Python

Germain Forestier, PhD

https://germain-forestier.info

Université de Haute-Alsace

Introduction à Python

Science des données

- Possibilité de faire de la science des données avec tous les langages : C, C++, Java, etc.
- Langages dédiés : R et Python

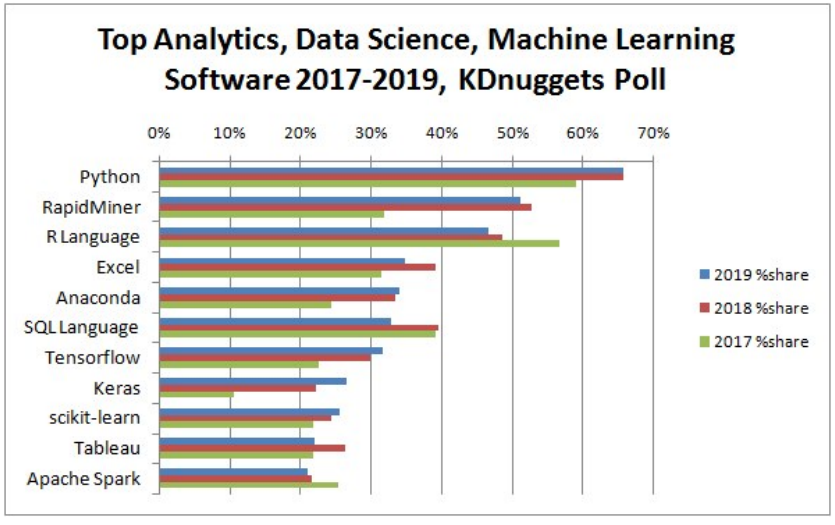

source : https://www.kdnuggets.com/

Anaconda

- Distribution Python (Python 2.x vs. Python 3.x)
- De nombreux paquets pré-installés
- Gestion automatique des dépendances entre paquets (`conda`)

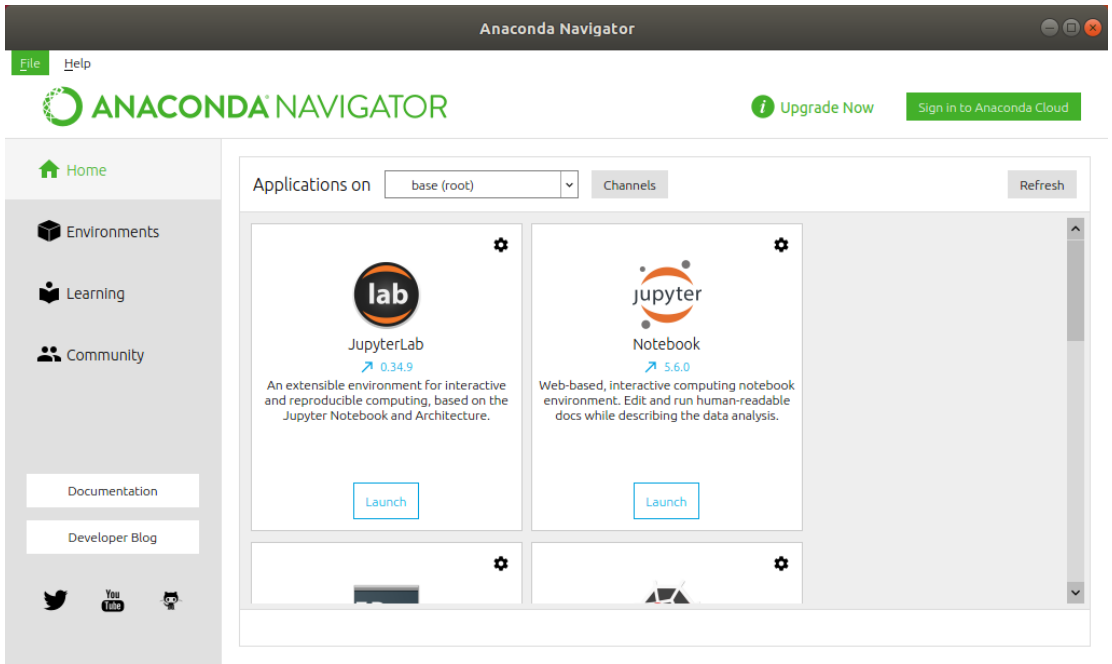

Spyder

- Éditeur simple pour Python (inclus dans Anaconda)
- Coloration syntaxique, exécution, etc.
- Console iPython, explorateur de variables, etc.

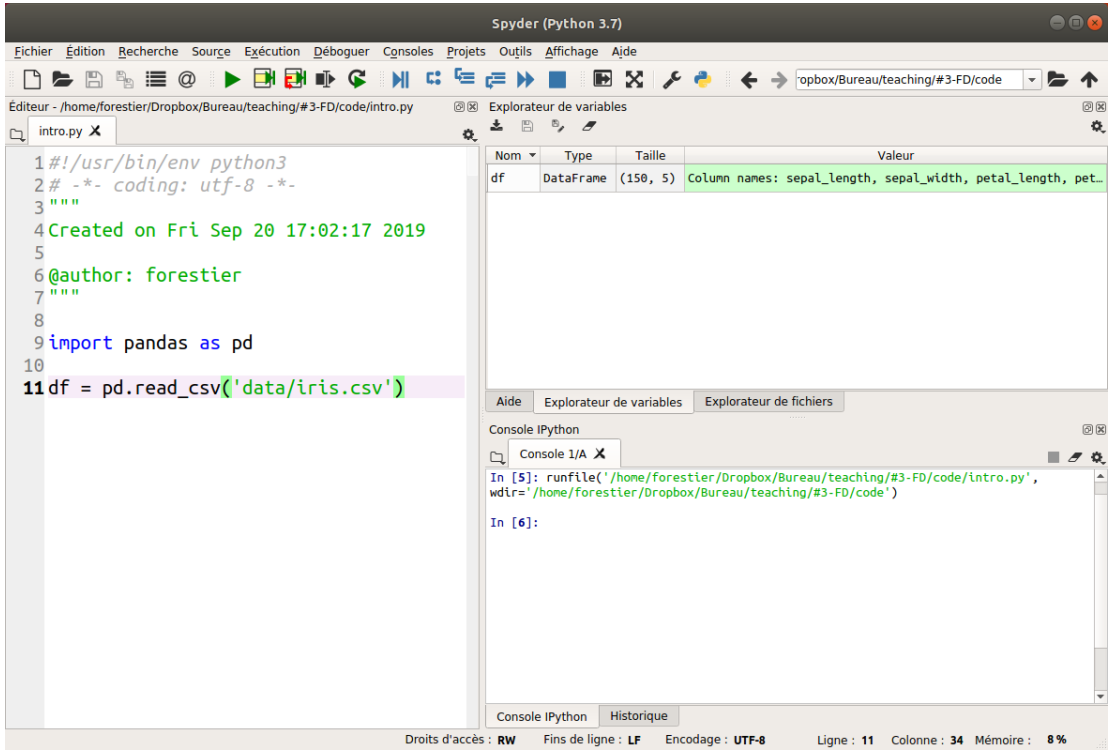

Google Colab

- Nécessite un compte Google
- Permets d'exécuter du code sur les serveurs Google
- Pratique si pas de possibilité d'installer des logiciels

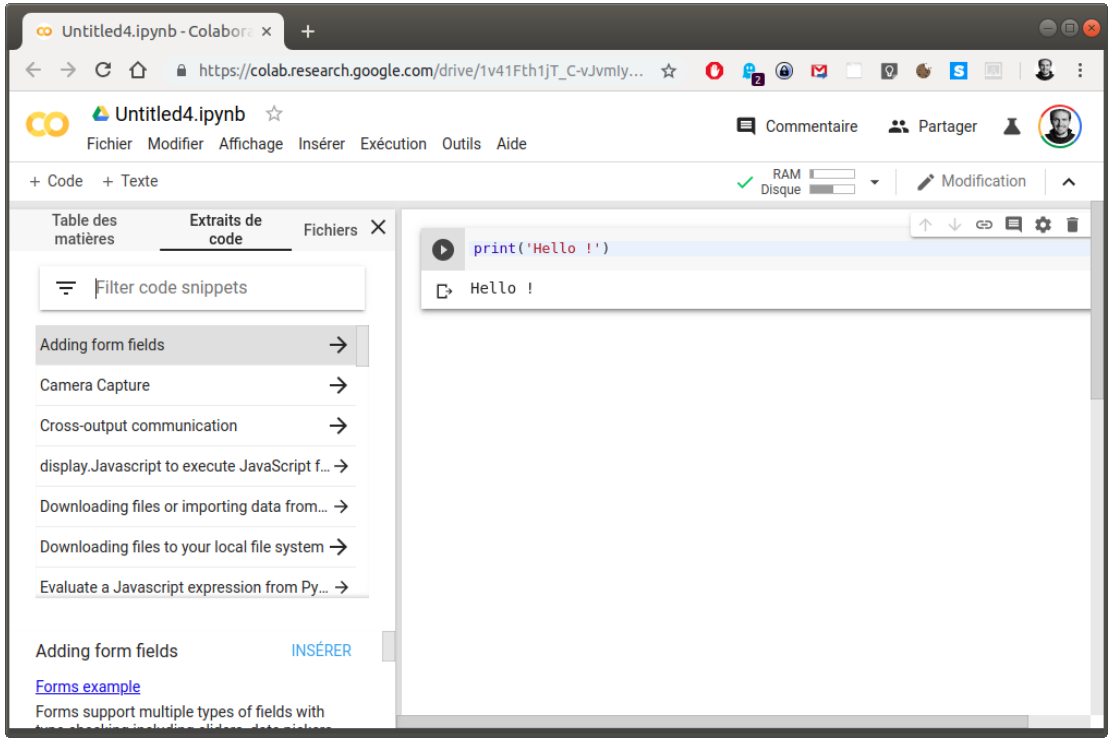

Types de données en Python

- `float` : nombre réel
- `int` : nombre entier
- `str` : chaîne de caractère, texte
- `bool` : vrai ou faux
- `type()` : renvoie le type d'une variable

Exemple :

```
height = 1.73
tall = True

In [1]: height = 1.79
In [2]: weight = 68.7

In [6]: bmi = weight / height ** 2

In [7]: bmi
Out[7]: 21.4413
```

Exercice

- Créer une variable `factor` égale à 1.10
- Utiliser `savings` et `factor` pour calculer le montant obtenu après 7 ans
- Afficher le résultat

```
# Create a variable savings
savings = 100

# Create a variable factor

# Calculate result

# Print out result
```

Corrigé

```
# Create a variable savings
savings = 100

# Create a variable factor
factor = 1.10

# Calculate result
results = savings * factor ** 7

# Print out result
print(results)
```

Exercice

- Exécuter le code ci-dessous et essayer de comprendre l'erreur
- Corriger le code à l'aide de la fonction `str()`
- Convertir la variable `pi_string` en float dans une nouvelle variable `pi_float`

```
# Definition of savings and result
savings = 100
result = 100 * 1.10 ** 7

# Fix the printout
print("I started with $" + savings + " and now have $" + result + ". Awesome!")

# Definition of pi_string
pi_string = "3.1415926"

# Convert pi_string into float: pi_float
```

Corrigé

```
# Definition of savings and result
savings = 100
result = 100 * 1.10 ** 7

# Fix the printout
print("I started with $" + str(savings) + " and now have $" + str(result) + ".
      Awesome!")

# Definition of pi_string
pi_string = "3.1415926"

# Convert pi_string into float: pi_float
pi_float = float(pi_string)
```

Exercice

- ▷ Laquelle de ces instructions Python lancera une erreur ?

Réponses

1. "I can add integers, like " + str(5) + " to strings."
2. "I said " + ("Hey " * 2) + "Hey!"
3. "The correct answer to this multiple choice exercise is answer number "+2
4. True + False

Exercice

- ▷ Laquelle de ces instructions Python lancera une erreur ?

Réponses

1. "I can add integers, like " + str(5) + " to strings."
2. "I said " + ("Hey " * 2) + "Hey!"
3. "The correct answer to this multiple choice exercise is answer number "+2
4. True + False

Les listes

Problème

- Science des données = de nombreuses données
- Tailles de toute une famille

```
In [3]: height1 = 1.73
In [4]: height2 = 1.68
In [5]: height3 = 1.71
In [6]: height4 = 1.89
```

- Pas très pratique...

Les listes en Python

- Exemple de liste :

```
fam = [1.73, 1.68, 1.71, 1.89]
```

- Permet de nommer une collection de valeurs
- Peut contenir n'importe quel type de données
- Peut contenir plusieurs types de données :

```
fam = ["liz", 1.73, "emma", 1.68, "mom", 1.71, "dad", 1.89]
```

- Possibilité de créer une liste de listes :

```
fam2 = [["liz", 1.73],
        ["emma", 1.68],
        ["mom", 1.71],
        ["dad", 1.89]]
```

Exercice

- Créer une liste, `areas`, qui contiendra la taille des différentes pièces
- Afficher la liste à l'aide de la fonction `print()`

```
# area variables (in square meters)
hall = 11.25
kit = 18.0
liv = 20.0
bed = 10.75
bath = 9.50

# Create list areas

# Print areas
```

Corrigé

```
1  # area variables (in square meters)
2  hall = 11.25
3  kit = 18.0
4  liv = 20.0
5  bed = 10.75
6  bath = 9.50
7
8  # Create list areas
9  areas = [hall,kit,liv,bed,bath]
10
11 # Print areas
12 print(areas)
```

Exercice

- Finir le code pour que chaque pièce possède son propre nom

```
# area variables (in square meters)
hall = 11.25
kit = 18.0
liv = 20.0
bed = 10.75
bath = 9.50

# Adapt list areas
areas = [hall, kit, "living room", liv, bed, "bathroom", bath]

# Print areas
```

Corrigé

```
1  # area variables (in square meters)
2  hall = 11.25
3  kit = 18.0
4  liv = 20.0
5  bed = 10.75
6  bath = 9.50
7
8  # Adapt list areas
9  areas = ["hallway", hall,"kitchen", kit, "living room", liv, "bedroom",bed, "
       bathroom", bath]
10
11 # Print areas
12 print(areas)
```

Exercice

▷ Parmi les instructions suivantes, lesquelles sont valides en Python ?

```
A. [1, 3, 4, 2]
B. [[1, 2, 3], [4, 5, 7]]
C. [1 + 2, "a" * 5, 3]
```

Réponses

1. A, B et C
2. B
3. B et C
4. C

Exercice

▷ Parmi les instructions suivantes, lesquelles sont valides en Python ?

```
A. [1, 3, 4, 2]
B. [[1, 2, 3], [4, 5, 7]]
C. [1 + 2, "a" * 5, 3]
```

Réponses

1. A, B et C
2. B
3. B et C
4. C

Exercice

- Terminer la liste de listes pour qu'elle contienne toutes les pièces puis afficher la variable `house` et son type (avec la fonction `type()`)

```
# area variables (in square meters)
hall = 11.25
kit = 18.0
liv = 20.0
bed = 10.75
bath = 9.50

# house information as list of lists
house = [["hallway", hall],
         ["kitchen", kit],
         ["living room", liv]]

# Print out house

# Print out the type of house
```

Corrigé

```
# area variables (in square meters)
hall = 11.25
kit = 18.0
liv = 20.0
bed = 10.75
bath = 9.50

# house information as list of lists
house = [["hallway", hall],
         ["kitchen", kit],
         ["living room", liv],
         ["bedroom", bed],
         ["bathroom", bath]]

# Print out house
print(house)

# Print out the type of house
print(type(house))
```

Récupération d'un élément d'une liste

```
In [1]: fam = ["liz", 1.73, "emma", 1.68, "mom", 1.71, "dad", 1.89]
In [3]: fam[3]
Out[3]: 1.68
In [5]: fam[-1]
Out[5]: 1.89
```

Découpage d'une liste (slicing)

```
In [1]: fam = ["liz", 1.73, "emma", 1.68, "mom", 1.71, "dad", 1.89]

In [8]: fam[3:5]
Out[8]: [1.68, 'mom']
```

`[début, fin]` ([inclus, exclus])

```
In [1]: fam = ["liz", 1.73, "emma", 1.68, "mom", 1.71, "dad", 1.89]

In [10]: fam[:4]
Out[10]: ['liz', 1.73, 'emma', 1.68]

In [11]: fam[5:]
Out[11]: [1.71, 'dad', 1.89]
```

Exercice

- Afficher le deuxième élément de la liste `areas` (11.25)
- Extraire et afficher le dernier élément de `areas` (9.5), utiliser un index négatif
- Sélectionner et afficher l'aire de "living room"

```
1 # Create the areas list
2 areas = ["hallway", 11.25, "kitchen", 18.0, "living room", 20.0, "bedroom",
      10.75, "bathroom", 9.50]
3
4 # Print out second element from areas
5
6 # Print out last element from areas
7
8 # Print out the area of the living room
```

Corrigé

```
1  # Create the areas list
2  areas = ["hallway", 11.25, "kitchen", 18.0, "living room", 20.0, "bedroom",
       10.75, "bathroom", 9.50]
3
4  # Print out second element from areas
5  print(areas[1])
6
7  # Print out last element from areas
8  print(areas[-1])
9
10 # Print out the area of the living room
11 print(areas[5])
```

Exercice

- Créer une variable `eat_sleep_area` qui contiendra la somme des aires de "kitchen" et "bedroom"
- Afficher cette nouvelle variable

```
# Create the areas list
areas = ["hallway", 11.25, "kitchen", 18.0, "living room", 20.0, "bedroom",
     10.75, "bathroom", 9.50]

# Sum of kitchen and bedroom area: eat_sleep_area

# Print the variable eat_sleep_area
```

Corrigé

```
# Create the areas list
areas = ["hallway", 11.25, "kitchen", 18.0, "living room", 20.0, "bedroom",
     10.75, "bathroom", 9.50]

# Sum of kitchen and bedroom area: eat_sleep_area
eat_sleep_area = areas[3] + areas[-3]

# Print the variable eat_sleep_area
print(eat_sleep_area)
```

Exercice

- Utiliser la sélection pour créer une liste ,`downstairs`, qui contient les 6 premiers éléments de `areas`
- Faire la même chose pour créer `upstairs` qui contiendra les 4 derniers éléments de `areas`

```
# Create the areas list
areas = ["hallway", 11.25, "kitchen", 18.0, "living room", 20.0, "bedroom",
     10.75, "bathroom", 9.50]

# Use slicing to create downstairs

# Use slicing to create upstairs

# Print out downstairs and upstairs
```

Corrigé

```
# Create the areas list
areas = ["hallway", 11.25, "kitchen", 18.0, "living room", 20.0, "bedroom",
     10.75, "bathroom", 9.50]

# Use slicing to create downstairs
downstairs = areas[0:6]

# Use slicing to create upstairs
upstairs = areas[6:10]

# Print out downstairs and upstairs
print(downstairs)
print(upstairs)
```

Exercice

- Utiliser la sélection pour créer les listes `downstairs` et `upstairs` en utilisant uniquement les indexes nécessaires

```
# Create the areas list
areas = ["hallway", 11.25, "kitchen", 18.0, "living room", 20.0, "bedroom",
     10.75, "bathroom", 9.50]

# Alternative slicing to create downstairs

# Alternative slicing to create upstairs
```

Corrigé

```
# Create the areas list
areas = ["hallway", 11.25, "kitchen", 18.0, "living room", 20.0, "bedroom",
     10.75, "bathroom", 9.50]

# Alternative slicing to create downstairs
downstairs = areas[:6]

# Alternative slicing to create upstairs
upstairs = areas[6:]
```

Exercice

- ▷ Que retournerait `house[-1][1]` ?

1. Un réel : la taille de "kitchen"
2. Une chaîne: "kitchen"
3. Un réel : a taille de "bathroom"
4. Une chaîne : "bathroom"

Exercice

- ▷ Que retournerait `house[-1][1]` ?

1. Un réel : la taille de "kitchen"
2. Une chaîne: "kitchen"
3. Un réel : a taille de "bathroom"
4. Une chaîne : "bathroom"

Changer une valeur dans une liste

```
In [1]: fam = ["liz", 1.73, "emma", 1.68, "mom", 1.71, "dad", 1.89]

In [2]: fam
Out[2]: ['liz', 1.73, 'emma', 1.68, 'mom', 1.71, 'dad', 1.89]

In [3]: fam[7] = 1.86

In [4]: fam
Out[4]: ['liz', 1.73, 'emma', 1.68, 'mom', 1.71, 'dad', 1.86]

In [5]: fam[0:2] = ["lisa", 1.74]

In [6]: fam
Out[6]: ['lisa', 1.74, 'emma', 1.68, 'mom', 1.71, 'dad', 1.86]
```

Ajouter et retirer un élément d'une liste

```
In [7]: fam + ["me", 1.79]
Out[7]: ['lisa', 1.74,'emma', 1.68,
         'mom', 1.71, 'dad', 1.86, 'me', 1.79]

In [8]: fam_ext = fam + ["me", 1.79]
In [9]: del(fam[2])

In [10]: fam
Out[10]: ['lisa', 1.74, 1.68, 'mom', 1.71, 'dad', 1.86]

In [11]: del(fam[2])

In [12]: fam
Out[12]: ['lisa', 1.74, 'mom', 1.71, 'dad', 1.86]
```

Exercice

- ▷ Changer la taille de la piscine en 10.50 à la place de 9.50
- ▷ Changer la pièce "living room" en "chill zone"

```
# Create the areas list
areas = ["hallway", 11.25, "kitchen", 18.0, "living room", 20.0, "bedroom",
     10.75, "bathroom", 9.50]

# Correct the bathroom area

# Change "living room" to "chill zone"
```

Corrigé

```
1 # Create the areas list
2 areas = ["hallway", 11.25, "kitchen", 18.0, "living room", 20.0, "bedroom",
      10.75, "bathroom", 9.50]
3
4 # Correct the bathroom area
5 areas[9] = 10.5
6
7 # Change "living room" to "chill zone"
8 areas[4] = "chill zone"
```

Exercice

- Utiliser l'opérateur + pour rajouter `["poolhouse", 24.5]` à la fin de la liste `areas`. Stocker le résultat dans `areas_1`
- Ajouter un garage à `areas_1` de taille 15.45 et stocker le résultat dans `areas_2`

```
# Create the areas list and make some changes
areas = ["hallway", 11.25, "kitchen", 18.0, "chill zone", 20.0,
         "bedroom", 10.75, "bathroom", 10.50]

# Add poolhouse data to areas, new list is areas_1

# Add garage data to areas_1, new list is areas_2
```

Corrigé

```
# Create the areas list and make some changes
areas = ["hallway", 11.25, "kitchen", 18.0, "chill zone", 20.0,
         "bedroom", 10.75, "bathroom", 10.50]

# Add poolhouse data to areas, new list is areas_1
areas_1 = areas + ["poolhouse", 24.5]

# Add garage data to areas_1, new list is areas_2
areas_2 = areas_1 + ["garage", 15.45]
```

Exercice

```
areas = ["hallway", 11.25, "kitchen", 18.0,
         "chill zone", 20.0, "bedroom", 10.75,
          "bathroom", 10.50, "poolhouse", 24.5,
          "garage", 15.45]
```

Quelle commande exécuter pour retirer la piscine ?

1. `del(areas[10]); del(areas[11])`
2. `del(areas[10:11])`
3. `del(areas[-4:-2])`
4. `del(areas[-3]); del(areas[-4])`

Exercice

```
areas = ["hallway", 11.25, "kitchen", 18.0,
         "chill zone", 20.0, "bedroom", 10.75,
          "bathroom", 10.50, "poolhouse", 24.5,
          "garage", 15.45]
```

Quelle commande exécuter pour retirer la piscine ?

1. `del(areas[10]); del(areas[11])`
2. `del(areas[10:11])`
3. `del(areas[-4:-2])`
4. `del(areas[-3]); del(areas[-4])`

Fonctions et packages

Les fonctions

```
In [1]: fam = [1.73, 1.68, 1.71, 1.89]

In [2]: fam
Out[2]: [1.73, 1.68, 1.71, 1.89]

In [3]: max(fam)
Out[3]: 1.89

In [4]: tallest = max(fam)

In [5]: tallest
Out[5]: 1.89

In [6]: round(1.68, 1)
Out[6]: 1.7

In [8]: help(round)
```

Exercice

- Utiliser `print()` avec `type()` pour afficher le type de `var1`
- Utiliser `len()` pour obtenir la longueur de `var1`
- Utiliser `int()` pour convertir `var2` en entier. Stocker le résultat dans `out2`

```
# Create variables var1 and var2
var1 = [1, 2, 3, 4]
var2 = True

# Print out type of var1

# Print out length of var1

# Convert var2 to an integer: out2
```

Corrigé

```
# Create variables var1 and var2
var1 = [1, 2, 3, 4]
var2 = True

# Print out type of var1
print(type(var1))

# Print out length of var1
print(len(var1))

# Convert var2 to an integer: out2
out2 = int(var2)
```

Exercice

- Utiliser + pour fusionner les contenus de `first` et `second` et stocker le résultat dans une liste `full`
- Appeler `sorted()` sur `full` et spécifier l'argument `reverse` à `True`. Enregistrer le résultat dans `full_sorted`.
- Terminer par afficher `full_sorted`.

```
# Create lists first and second
first = [11.25, 18.0, 20.0]
second = [10.75, 9.50]

# Paste together first and second: full

# Sort full in descending order: full_sorted

# Print out full_sorted
```

Corrigé

```
# Create lists first and second
first = [11.25, 18.0, 20.0]
second = [10.75, 9.50]

# Paste together first and second: full
full = first + second

# Sort full in descending order: full_sorted
full_sorted = sorted(full, reverse=True)

# Print out full_sorted
print(full_sorted)
```

Méthodes `list`

```
In [4]: fam
Out[4]: ['liz', 1.73, 'emma', 1.68, 'mom', 1.71, 'dad', 1.89]

In [5]: fam.index("mom")
Out[5]: 4

In [6]: fam.count(1.73)
Out[6]: 1
```

Méthodes `srt`

```
In [7]: sister
Out[7]: 'liz'

In [8]: sister.capitalize()
Out[8]: 'Liz'

In [9]: sister.replace("z", "sa")
Out[9]: 'lisa'
```

Exercice

- Utiliser la méthode `upper()` sur "room" et stocker le résultat dans `room_up`
- Afficher `room` et `room_up`
- Afficher le nombre de" o" dans la variable `room` en appelant la méthode `count()` sur `room`

```
# string to experiment with: room
room = "poolhouse"

# Use upper() on room: room_up

# Print out room and room_up

# Print out the number of o's in room
```

Corrigé

```
# string to experiment with: room
room = "poolhouse"

# Use upper() on room: room_up
room_up = room.upper()

# Print out room and room_up
print(room)
print(room_up)

# Print out the number of o's in room
print(room.count("o"))
```

Exercice

- Utiliser la méthode `index()` pour obtenir l'index de l'élément égal à 20.0. Afficher cet index.
- Appeler la méthode `count()` sur `areas` afin de trouver combien de fois 14.5 apparaît dans la liste. Afficher le résultat.

```
# Create list areas
areas = [11.25, 18.0, 20.0, 10.75, 9.50]

# Print out the index of the element 20.0

# Print out how often 14.5 appears in areas
```

Corrigé

```
# Create list areas
areas = [11.25, 18.0, 20.0, 10.75, 9.50]

# Print out the index of the element 20.0
print(areas.index(20.0))

# Print out how often 14.5 appears in areas
print(areas.count(14.5))
```

Exercice

- Utiliser `append()` deux fois afin d'ajouter la taille de poolhouse et garage : 24.5 and 15.45
- Afficher `areas`
- Utiliser la méthode `reverse()` afin de d'inverser l'ordre des éléments de `areas`
- Afficher `areas`

```
# Create list areas
areas = [11.25, 18.0, 20.0, 10.75, 9.50]

# Use append twice to add poolhouse and garage size

# Print out areas

# Reverse the orders of the elements in areas

# Print out areas
```

Corrigé

```
# Create list areas
areas = [11.25, 18.0, 20.0, 10.75, 9.50]

# Use append twice to add poolhouse and garage size
areas.append(24.5)
areas.append(15.45)

# Print out areas
print(areas)

# Reverse the orders of the elements in areas
areas.reverse()

# Print out areas
print(areas)
```

Packages

- Ensemble de scripts Python
- Spécifie des fonctions, des méthodes et des types
- Des milliers de packages sont disponibles (Numpy, Matplotlib, Scikit-learn)

```
1 import numpy
2 numpy.array([1, 2, 3])
3
4 import numpy as np
5 np.array([1, 2, 3])
6
7 from numpy import array
8 array([1, 2, 3])
```

Exercice

- Importer le package `math`. Vous pouvez maintenant utiliser `math.pi`
- Calculer la circonférence du cercle et stocker le dans `C`
- Calculer l'aire du cercle et stocker le dans `A`

```
# Definition of radius
r = 0.43

# Import the math package

# Calculate C
C = 0

# Calculate A
A = 0

# Build printout
print("Circumference: " + str(C))
print("Area: " + str(A))
```

Corrigé

```
1  # Definition of radius
2  r = 0.43
3
4  # Import the math package
5  import math
6
7  # Calculate C
8  C = 2 * math.pi * r
9
10 # Calculate A
11 A = math.pi * r ** 2
12
13 # Build printout
14 print("Circumference: " + str(C))
15 print("Area: " + str(A))
```

Exercice

- Effectuer un import sélectif du package `math` pour importer uniquement la fonction `radians`
- Calculer la distance parcourue par la lune sur 12 degrés de son orbite. Assigner le résultat à `dist`. Vous pouvez la calculer par `r * phi`, où `r` est le rayon et `phi` est l'angle en radians. Pour convertir l'angle de degré à radians, utiliser la fonction `radians()` que vous venez d'importer
- Afficher `dist`

```
# Definition of radius
r = 192500

# Import radians function of math package

# Travel distance of Moon over 12 degrees. Store in dist.

# Print out dist
```

Corrigé

```
# Definition of radius
r = 192500

# Import radians function of math package
from math import radians

# Travel distance of Moon over 12 degrees. Store in dist.
dist = r * radians(12)

# Print out dist
print(dist)
```

Numpy

Numpy

- Numerical Python
- Alternative aux listes Python : Numpy Array
- Facilite les calculs sur des tableaux
- Simple et rapide

Numpy

```
In [6]: import numpy as np

In [7]: np_height = np.array(height)

In [8]: np_height
Out[8]: array([ 1.73, 1.68, 1.71, 1.89, 1.79])

In [9]: np_weight = np.array(weight)

In [10]: np_weight
Out[10]: array([ 65.4, 59.2, 63.6, 88.4, 68.7])

In [11]: bmi = np_weight / np_height ** 2

In [12]: bmi
Out[12]: array([ 21.852, 20.975, 21.75, 24.747,21.441])
```

Numpy

- Numpy Array ne contient qu'un seul type

```
In [19]: np.array([1.0, "is", True])
Out[19]: array(['1.0', 'is', 'True'], dtype='<U32')
NumPy arrays: contain only one type

In [20]: python_list = [1, 2, 3]

In [21]: numpy_array = np.array([1, 2, 3])

In [22]: python_list + python_list
Out[22]: [1, 2, 3, 1, 2, 3]

In [23]: numpy_array + numpy_array
Out[23]: array([2, 4, 6])
```

Numpy

- Numpy Array sélection

```
In [24]: bmi
Out[24]: array([ 21.852, 20.975, 21.75, 24.747, 21.441])

In [25]: bmi[1]
Out[25]: 20.975

In [26]: bmi > 23
Out[26]: array([False, False, False, True, False], dtype=bool)

In [27]: bmi[bmi > 23]
Out[27]: array([ 24.747])
```

Exercice

- Importer le package `numpy` avec l'alias `np`
- Utiliser `np.array()` pour créer un tableau `numpy` à partir de `baseball`. Appeler le `np_baseball`
- Afficher le type de `np_baseball` pour vérifier son type.

```
# Create list baseball
baseball = [180, 215, 210, 210, 188, 176, 209, 200]

# Import the numpy package as np

# Create a numpy array from baseball: np_baseball

# Print out type of np_baseball
```

Corrigé

```
# Create list baseball
baseball = [180, 215, 210, 210, 188, 176, 209, 200]

# Import the numpy package as np
import numpy as np

# Create a numpy array from baseball: np_baseball
np_baseball = np.array(baseball)

# Print out type of np_baseball
print(type(np_baseball))
```

Exercice

- Créer un tableau numpy height appelé np_height
- Afficher np_height
- Multiplier np_height par 0.0254 afin de convertir le tableau des pouces aux mètres. Stocker les valeurs dans np_height_m
- Afficher np_height_m et vérifier le résultat

```
1  # height is available as a regular list
2  from baseballdata import *
3
4  # Import numpy
5  import numpy as np
6
7  # Create a numpy array from height: np_height
8
9  # Print out np_height
10
11 # Convert np_height to m: np_height_m
12
13 # Print np_height_m
```

https://germain-forestier.info/teaching/files/DS/baseballdata.py

Corrigé

```
# height is available as a regular list
from baseballdata import *

# Import numpy
import numpy as np

# Create a numpy array from height: np_height
np_height = np.array(height)

# Print out np_height
print(np_height)

# Convert np_height to m: np_height_m
np_height_m = np_height * 0.0254

# Print np_height_m
print(np_height_m)
```

Exercice

- Créer un tableau numpy pour la liste de poids avec la bonne unité. Multiplier par 0.453592 pour passer des livres aux kilos. Stocker le résultat dans `np_weight_kg`
- Utiliser `np_height_m` and `np_weight_kg` pour calculer le BMI (IMC) de chaque joueur. Utiliser l'équation suivante : $BMI = \frac{weight(kg)}{height(m)^2}$
- Stocker le résultat dans la variable `bmi` et l'afficher

```
# height and weight are available as a regular lists
from baseballdata import *

# Import numpy
import numpy as np

# Create array from height with correct units: np_height_m
np_height_m = np.array(height) * 0.0254

# Create array from weight with correct units: np_weight_kg

# Calculate the BMI: bmi

# Print out bmi
```

Corrigé

```
# height and weight are available as a regular lists
from baseballdata import *

# Import numpy
import numpy as np

# Create array from height with correct units: np_height_m
np_height_m = np.array(height) * 0.0254

# Create array from weight with correct units: np_weight_kg
np_weight_kg = np.array(weight) * 0.453592

# Calculate the BMI: bmi
bmi = np_weight_kg / np_height_m ** 2

# Print out bmi
print(bmi)
```

Exercice

- Créer un tableau numpy de boolean: les éléments du tableau doivent être True si le BMI du joueur correspondant est inférieur à 21 (vous pouvez utiliser l'opérateur $<$). Nommer le tableau `light` et l'afficher.
- Afficher un tableau numpy avec les BMI de tous les joueurs qui ont un BMI inférieur à 21. Utiliser le tableau `light` pour faire la sélection sur `bmi`.

```
# height and weight are available as a regular lists
from baseballdata import *

# Import numpy
import numpy as np

# Calculate the BMI: bmi
np_height_m = np.array(height) * 0.0254
np_weight_kg = np.array(weight) * 0.453592
bmi = np_weight_kg / np_height_m ** 2

# Create the light array

# Print out light

# Print out BMIs of all baseball players whose BMI is below 21
```

Corrigé

```
# height and weight are available as a regular lists
from baseballdata import *

# Import numpy
import numpy as np

# Calculate the BMI: bmi
np_height_m = np.array(height) * 0.0254
np_weight_kg = np.array(weight) * 0.453592
bmi = np_weight_kg / np_height_m ** 2

# Create the light array
light = bmi < 21

# Print out light
print(light)

# Print out BMIs of all baseball players whose BMI is below 21
print(bmi[light])
```

Exercice

Quelle proposition donnerait le même résultat que :

```
1 np.array([True, 1, 2]) + np.array([3, 4, False])
```

1. `np.array([True, 1, 2, 3, 4, False])`
2. `np.array([4, 3, 0]) + np.array([0, 2, 2])`
3. `np.array([1, 1, 2]) + np.array([3, 4, -1])`
4. `np.array([0, 1, 2, 3, 4, 5])`

Exercice

Quelle proposition donnerait le même résultat que :

```
1 np.array([True, 1, 2]) + np.array([3, 4, False])
```

1. `np.array([True, 1, 2, 3, 4, False])`
2. `np.array([4, 3, 0]) + np.array([0, 2, 2])`
3. `np.array([1, 1, 2]) + np.array([3, 4, -1])`
4. `np.array([0, 1, 2, 3, 4, 5])`

Exercice

- Afficher l'élément à l'index 50 de `np_weight`
- Afficher le sous tableau de `np_weight` qui contient les éléments de 100 à 110 inclus

```
# height and weight are available as a regular lists
from baseballdata import *

# Import numpy
import numpy as np

# Store weight and height lists as numpy arrays
np_weight = np.array(weight)
np_height = np.array(height)

# Print out the weight at index 50

# Print out sub-array of np_height: index 100 up to and including index 110
```

Corrigé

```
# height and weight are available as a regular lists
from baseballdata import *

# Import numpy
import numpy as np

# Store weight and height lists as numpy arrays
np_weight = np.array(weight)
np_height = np.array(height)

# Print out the weight at index 50
print(np_weight[50])

# Print out sub-array of np_height: index 100 up to and including index 110
print(np_height[100:111])
```

2D Numpy Arrays

- Tableau à deux dimensions

```
In [6]: np_2d = np.array([[1.73, 1.68, 1.71, 1.89, 1.79],
                          [65.4, 59.2, 63.6, 88.4, 68.7]])

In [7]: np_2d
Out[7]:
array([[ 1.73, 1.68, 1.71, 1.89, 1.79],
       [ 65.4, 59.2, 63.6, 88.4, 68.7 ]])

In [8]: np_2d.shape
Out[8]: (2, 5)

In [9]: np.array([[1.73, 1.68, 1.71, 1.89, 1.79],
                  [65.4, 59.2, 63.6, 88.4, "68.7"]])

out[9]:
array([['1.73', '1.68', '1.71', '1.89', '1.79'],
       ['65.4', '59.2', '63.6', '88.4', '68.7']],
dtype='<U32')
```

2D Numpy Arrays

- Sélection dans un tableau 2D

```
In [10]: np_2d[0]
Out[10]: array([ 1.73, 1.68, 1.71, 1.89, 1.79])

In [11]: np_2d[0][2]
Out[11]: 1.71

In [12]: np_2d[0,2]
Out[12]: 1.71

In [13]: np_2d[:,1:3]
Out[13]:
array([[ 1.68, 1.71],
       [ 59.2, 63.6 ]])

In [14]: np_2d[1,:]
Out[14]: array([ 65.4, 59.2, 63.6, 88.4, 68.7])
```

Exercice

- Utiliser `np.array()` pour créer un tableau numpy 2D pour baseball, appeler le `np_baseball` et afficher le
- Afficher la forme du tableau, utiliser `np_baseball.shape`

```
# Create baseball, a list of lists
baseball = [[180, 78.4],
            [215, 102.7],
            [210, 98.5],
            [188, 75.2]]

# Import numpy
import numpy as np

# Create a 2D numpy array from baseball: np_baseball

# Print out the type of np_baseball

# Print out the shape of np_baseball
```

Corrigé

```
# Create baseball, a list of lists
baseball = [[180, 78.4],
            [215, 102.7],
            [210, 98.5],
            [188, 75.2]]

# Import numpy
import numpy as np

# Create a 2D numpy array from baseball: np_baseball
np_baseball = np.array(baseball)

# Print out the type of np_baseball
print(type(np_baseball))

# Print out the shape of np_baseball
print(np_baseball.shape)
```

Exercice

- Utiliser `np.array()` pour créer un tableau numpy 2D à partir de `baseball` et l'appeler `np_baseball`
- Afficher la forme de `np_baseball`

```
# baseball is available as a regular list of lists
from baseballdata import *

# Import numpy package
import numpy as np

# Create a 2D numpy array from baseball: np_baseball

# Print out the shape of np_baseball
```

Corrigé

```
# baseball is available as a regular list of lists
from baseballdata import *

# Import numpy package
import numpy as np

# Create a 2D numpy array from baseball: np_baseball
np_baseball = np.array(baseball)

# Print out the shape of np_baseball
print(np_baseball.shape)
```

Exercice

- Afficher la 50ème ligne de `np_baseball`
- Créer une nouvelle variable, `np_weight`, contenant la deuxième colonne de `np_baseball`
- Sélectionner la taille (première colonne) du joueur 124 dans `np_baseball` et l'afficher

```
# baseball is available as a regular list of lists
from baseballdata import *

# Import numpy package
import numpy as np

# Create np_baseball (2 cols)
np_baseball = np.array(baseball)

# Print out the 50th row of np_baseball

# Select the entire second column of np_baseball: np_weight

# Print out height of 124th player
```

Corrigé

```
# baseball is available as a regular list of lists
from baseballdata import *

# Import numpy package
import numpy as np

# Create np_baseball (2 cols)
np_baseball = np.array(baseball)

# Print out the 50th row of np_baseball
print(np_baseball[49,:])

# Select the entire second column of np_baseball: np_weight
np_weight = np_baseball[:,1]

# Print out height of 124th player
print(np_baseball[123, 0])
```

Exercice

- Vous avez récupéré les changements de poids taille et age des joueurs de baseball. Ils sont stockés dans le tableau numpy 2D `array`. Ajouter `np_baseball` et `updated` et afficher le résultat.
- Vous souhaitez convertir les unités de taille et poids. Créer une tableau numpy avec les valeurs 0.0254, 0.453592 et 1. Nommer ce tableau `conversion`. Multiplier `np_baseball` et `conversion` et afficher le résultat.

```
# updated is available as 2D numpy array
from baseballdata2 import *

# Import numpy package
import numpy as np

# Create np_baseball (3 cols)
np_baseball = np.array(baseball)

# Print out addition of np_baseball and updated

# Create numpy array: conversion

# Print out product of np_baseball and conversion
```

https://germain-forestier.info/teaching/files/DS/baseballdata2.py

Corrigé

```
# baseball is available as a regular list of lists
# updated is available as 2D numpy array
from baseballdata2 import *

# Import numpy package
import numpy as np

# Create np_baseball (3 cols)
np_baseball = np.array(baseball)

# Print out addition of np_baseball and updated
print(np_baseball + updated)

# Create numpy array: conversion
conversion = np.array([0.0254, 0.453592, 1])

# Print out product of np_baseball and conversion
print(np_baseball * conversion)
```

Numpy statistiques

- Comprendre vos données
- Peu de données : simplement les observer
- Beaucoup de données : ?

```
In [1]: import numpy as np
In [2]: np_city = ... # Implementation left out
In [3]: np_city
Out[3]:
array([[ 1.64, 71.78],
[ 1.37, 63.35],
[ 1.6 , 55.09],
...,
[ 2.04, 74.85],
[ 2.04, 68.72],
[ 2.01, 73.57]])
```

Numpy statistiques

```
In [4]: np.mean(np_city[:,0])
Out[4]: 1.7472

In [5]: np.median(np_city[:,0])
Out[5]: 1.75

In [6]: np.corrcoef(np_city[:,0], np_city[:,1])
Out[6]:
array([[ 1., -0.01802],
       [-0.01803, 1.]])

In [7]: np.std(np_city[:,0])
Out[7]: 0.1992
```

- `sum()`, `sort()`, ...

Exercice

- Créer un tableau numpy `np_height` qui contient la première colonne de `np_baseball`
- Afficher la moyenne de `np_height`
- Afficher le médiane de `np_height`
- Constatez vous une erreur ? Quelle statistique est la plus adaptée pour détecter cette erreur ?

```
# np_baseball is available
from baseballdata3 import *

# Import numpy
import numpy as np

# Create np_height from np_baseball

# Print out the mean of np_height

# Print out the median of np_height
```

https://germain-forestier.info/teaching/files/DS/baseballdata3.py

Corrigé

```
# np_baseball is available
from baseballdata3 import *

# Import numpy
import numpy as np

# Create np_height from np_baseball
np_height = np_baseball[:,0]

# Print out the mean of np_height
print(np.mean(np_height))

# Print out the median of np_height
print(np.median(np_height))
```

Exercice

- Compléter le code pour calculer la médiane.
- Utiliser `np.std()` sur la première colonne de `np_baseball`.
- Est-ce-que les grands joueurs sont plus lourd ? Utiliser `np.corrcoef()` pour stocker la corrélation entre la première et le deuxième colonne de `np_baseball` dans `corr`.

```
# np_baseball is available
from baseballdata3 import *

# Print mean height (first column)
avg = np.mean(np_baseball[:,0])
print("Average: " + str(avg))

# Print median height. Replace 'None'
med = None
print("Median: " + str(med))

# Print out the standard deviation on height. Replace 'None'
stddev = None
print("Standard Deviation: " + str(stddev))

# Print out correlation between first and second column. Replace 'None'
corr = None
print("Correlation: " + str(corr))
```

Corrigé

```
# np_baseball is available
from baseballdata3 import *

# Import numpy
import numpy as np

# Print mean height (first column)
avg = np.mean(np_baseball[:,0])
print("Average: " + str(avg))

# Print median height. Replace 'None'
med = np.median(np_baseball[:,0])
print("Median: " + str(med))

# Print out the standard deviation on height. Replace 'None'
stddev = np.std(np_baseball[:,0])
print("Standard Deviation: " + str(stddev))

# Print out correlation between first and second column. Replace 'None'
corr = np.corrcoef(np_baseball[:,0],np_baseball[:,1])
print("Correlation: " + str(corr))
```

Exercice

- Convertir `heights` et `positions` en tableaux numpy
- Extraire les tailles des goalkeepers dans `gk_heights` (utiliser `np_positions == 'GK'`)
- Extraire les tailles des autres joueurs dans `other_heights` (utiliser `np_positions != 'GK'`)
- Afficher la taille médiane des goalkeepers avec `np.median()`
- Afficher la taille médiane des autres joueurs avec `np.median()`

```
# heights and positions are available as lists
from foot import *

# Convert positions and heights to numpy arrays: np_positions, np_heights

# Heights of the goalkeepers: gk_heights

# Heights of the other players: other_heights

# Print out the median height of goalkeepers. Replace 'None'
print("Median height of goalkeepers: " + str(None))

# Print out the median height of other players. Replace 'None'
print("Median height of other players: " + str(None))
```

Corrigé

```python
# heights and positions are available as lists
from foot import *

# Import numpy
import numpy as np

# Convert positions and heights to numpy arrays: np_positions, np_heights
np_heights = np.array(heights)
np_positions = np.array(positions)

# Heights of the goalkeepers: gk_heights
gk_heights = np_heights[np_positions == 'GK' ]

# Heights of the other players: other_heights
other_heights = np_heights[np_positions != 'GK' ]

# Print out the median height of goalkeepers. Replace 'None'
mhg = np.median(gk_heights)
print("Median height of goalkeepers: " + str(mhg))

# Print out the median height of other players. Replace 'None'
mho = np.median(other_heights)
print("Median height of other players: " + str(mho))
```

https://germain-forestier.info/teaching/files/DS/foot.py

Pandas

Pandas

- Package haut-niveau pour la manipulation de données
- Basé sur Numpy
- Permet de gérer des données de différents types
- L'objet `DataFrame` permet de manipuler les données

```
1  import numpy as np
2  import pandas as pd
3
4  df = pd.DataFrame({'A' : 1.,
5  'B' : pd.Timestamp('20130102'),
6  'C' : pd.Series(1,index=list(range(4)),dtype='float32'),
7  'D' : np.array([3] * 4,dtype='int32'),
8  'E' : pd.Categorical(["test","train","test","train"]),
9  'F' : 'foo' })
10
11 print(df)
12 print(df.dtypes)
```

Pandas

- Package haut-niveau pour la manipulation de données
- Basé sur Numpy
- Permet de gérer des données de différents types
- L'objet `DataFrame` permet de manipuler les données

```
     A          B    C  D      E    F
0  1.0 2013-01-02  1.0  3   test  foo
1  1.0 2013-01-02  1.0  3  train  foo
2  1.0 2013-01-02  1.0  3   test  foo
3  1.0 2013-01-02  1.0  3  train  foo

print(df.dtypes)
A            float64
B    datetime64[ns]
C            float32
D              int32
E           category
F             object
dtype: object
```

Pandas

- L'objet DataFrame permet de faire de la sélection de données
- La fonction `loc` permet de recherche par nom
- La fonction `iloc` permet de recherche par index

```
df['A']
df[['A','B']]
df[0:3]

# recherche par nom
df.loc[:,['A','B']]

# recherche par index
df.iloc[3]
df.iloc[1:3]
```

Pandas

Python Pandas Selections and Indexing

.iloc selections - position based selection

data.iloc[<row selection], <column selection>]

Integer list of rows: [0,1,2]
Slice of rows: [4:7]
Single values: 1

Integer list of columns: [0,1,2]
Slice of columns: [4:7]
Single column selections: 1

loc selections - position based selection

data.loc[<row selection], <column selection>]

Index/Label value: 'john'
List of labels: ['john', 'sarah']
Logical/Boolean index: data['age'] == 10

Named column: 'first_name'
List of column names: ['first_name', 'age']
Slice of columns: 'first_name':'address'

https://www.shanelynn.ie/select-pandas-dataframe-rows-and-columns-using-iloc-loc-and-ix/

Lire des données

Lire de données

- Il est souvent nécessaire de lire des données depuis des fichiers afin de les traiter et de pouvoir construire des modèles prédictifs
- La fonction `genfromtxt()` de Numpy permet de lire des fichiers, mais uniquement avec des attributs de même type
- La fonction `read_csv()` de Pandas permet de lire des fichiers avec des types d'attributs différents

```
1 # lecture de données avec Numpy
2 import numpy as np
3 data = np.genfromtxt('data/iris.csv', delimiter=',',skip_header=True)
4
5 # lecture de données avec Pandas
6 import pandas as pd
7 df = pd.read_csv('data/iris.csv', header=0)
```

Visualisation de données

Visualisation de données

- Très important en analyse de données
- Permet d'explorer les données
- Permet de rapporter des résultats
- Matplotlib permet de facilement visualiser des données

```
1 import matplotlib.pyplot as plt
2
3 year = [1950, 1970, 1990, 2010]
4 pop = [2.519, 3.692, 5.263, 6.972]
5
6 plt.plot(year, pop)
7 plt.show()
```

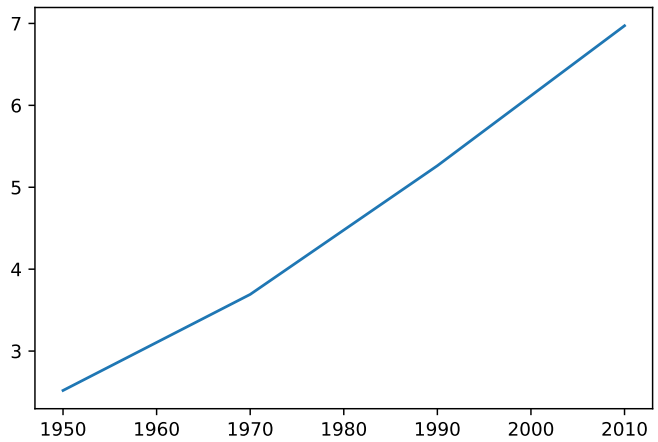

Visualisation de données

- Très important en analyse de données
- Permet d'explorer les données
- Permet de rapporter des résultats
- Matplotlib permet de facilement visualiser des données

```
1 import matplotlib.pyplot as plt
2
3 year = [1950, 1970, 1990, 2010]
4 pop = [2.519, 3.692, 5.263, 6.972]
5
6 plt.scatter(year, pop)
7 plt.show()
```

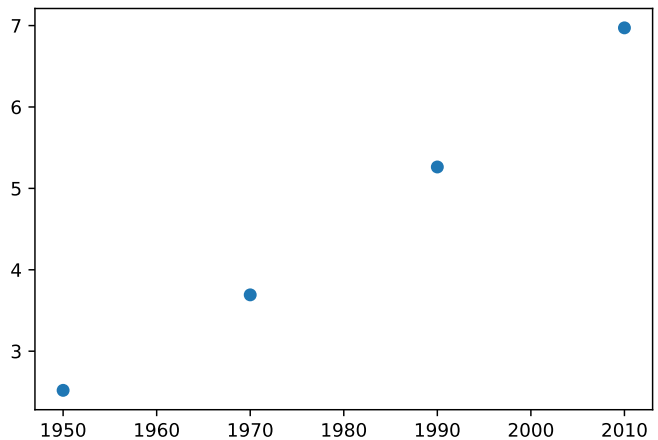

Visualisation de données

- Très important en analyse de données
- Permet d'explorer les données
- Permet de rapporter des résultats
- Matplotlib permet de facilement visualiser des données

```
1  import matplotlib.pyplot as plt
2
3  year = [1950, 1970, 1990, 2010]
4  pop = [2.519, 3.692, 5.263, 6.972]
5
6  plt.title('Evolution de la population')
7  plt.xlabel('Années')
8  plt.ylabel('Milliards d\'habitans')
9  plt.scatter(year, pop)
10 plt.show()
```

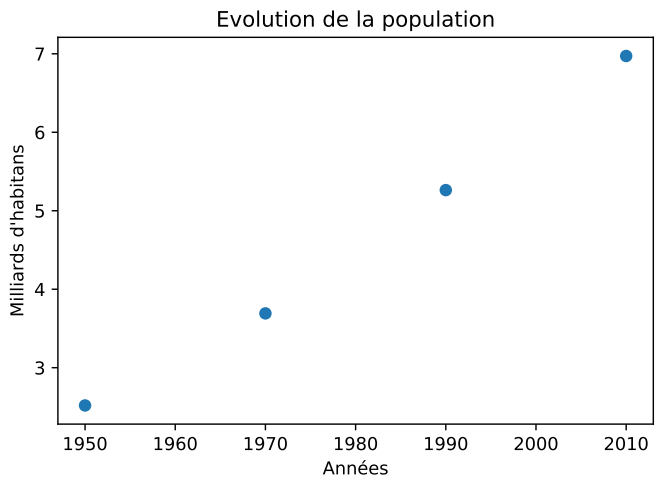

Exercice

- Récupérer le fichier "iris.csv"[1]
- Importer les données à l'aide de `read_csv()` de `pandas`
- Générer le graphique suivant à l'aide de `matplotlib` (choisir deux caractéristiques) :

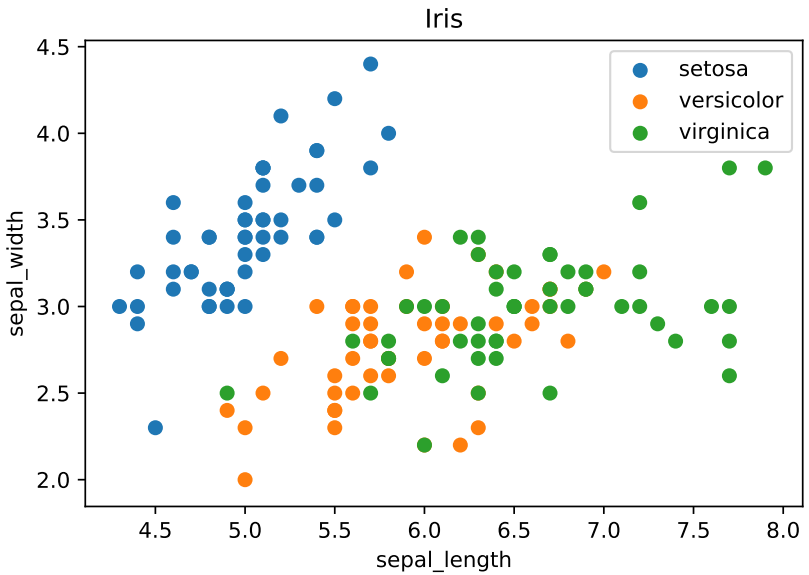

[1] `https://germain-forestier.info/teaching/files/FD/dataset/iris.csv`

Corrigé

```
1  import matplotlib.pyplot as plt
2  import pandas as pd
3
4  df = pd.read_csv('data/iris.csv', header=0)
5
6  subset = df[df['species'] == 'setosa']
7  plt.scatter(subset['sepal_length'], subset['sepal_width'], label='setosa')
8
9  subset = df[df['species'] == 'versicolor']
10 plt.scatter(subset['sepal_length'], subset['sepal_width'], label='versicolor')
11
12 subset = df[df['species'] == 'virginica']
13 plt.scatter(subset['sepal_length'], subset['sepal_width'], label='virginica')
14
15 plt.xlabel('sepal_length')
16 plt.ylabel('sepal_width')
17 plt.title('Iris')
18 plt.legend()
```

Visualisation de données

- Le package Seaborn est une alternative à Matplotlib
- Rajoute des fonctionnalités
- Permet de faire des visualisations avancées

```
1 import seaborn as sns
2 import pandas as pd
3
4 df = pd.read_csv('data/iris.csv', header=0)
5
6 ax = sns.pairplot(df, hue='species', height=1)
```

https://seaborn.pydata.org/

Visualisation de données

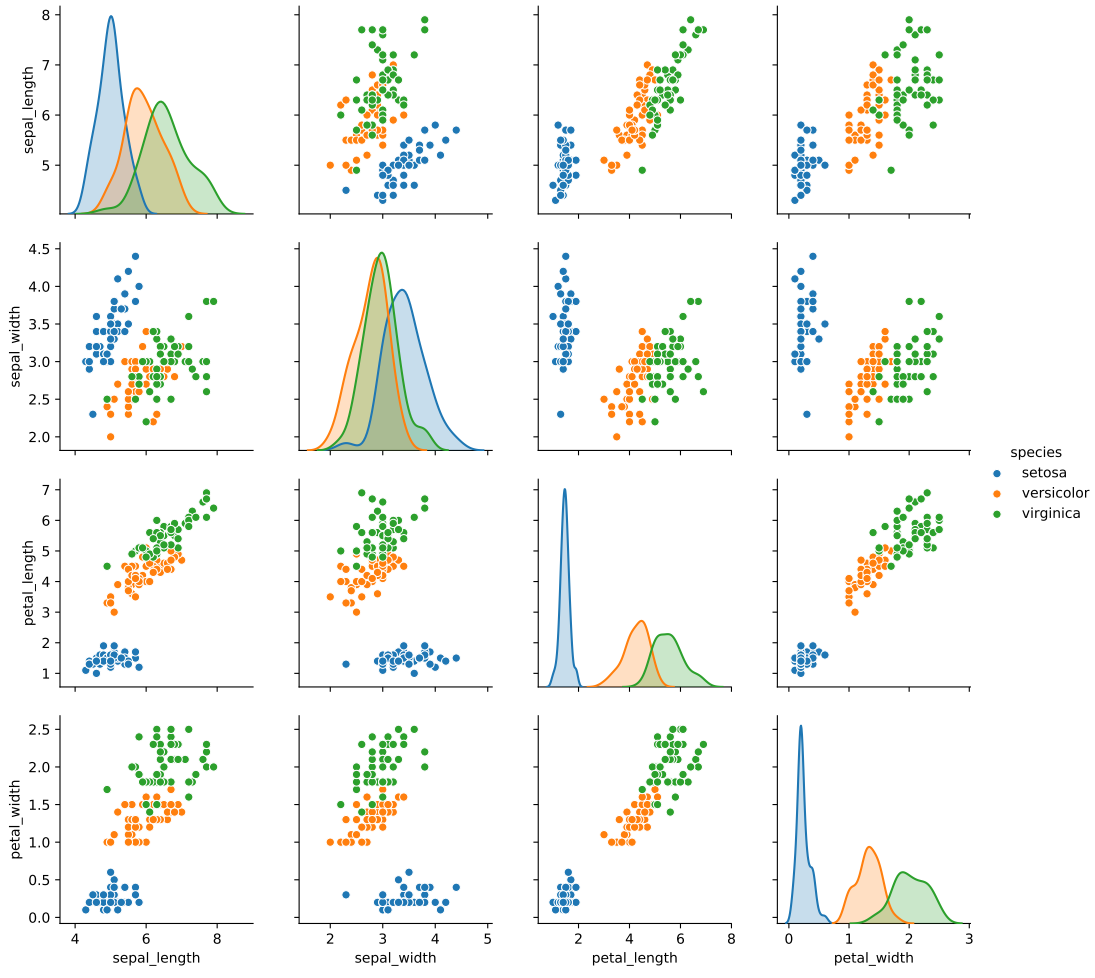

Validation

Validation (train/test)

- Afin de pouvoir valider un modèle, il est important de pouvoir tester sa capacité à faire de bonnes prédictions
- On évite de tester un modèle sur les mêmes données utilisées pour construire le modèle
- Si on utilise les mêmes données, les performances auront tendance à être surévaluées et on ne teste pas la capacité de généralisation
- La méthode la plus classique consiste à découper le jeu de données en deux ensembles, un pour l'apprentissage (*train*) et un pour l'évaluation (*test*)

Validation (train/test)

- On garde 80% des données pour l'apprentissage et 20% pour le test :

```
1 import pandas as pd
2 import numpy as np
3
4 df = pd.read_csv('data/iris.csv', header=0)
5 mask = np.random.rand(len(df)) < 0.8
6 df_train = df[mask]
7 df_test = df[~mask]
```

- Il faut faire attention à la distribution des classes (nombre d'éléments de chaque classe qui peut être différent)
- Afin de conserver la même distribution, on parle de stratification

Validation (train/test)

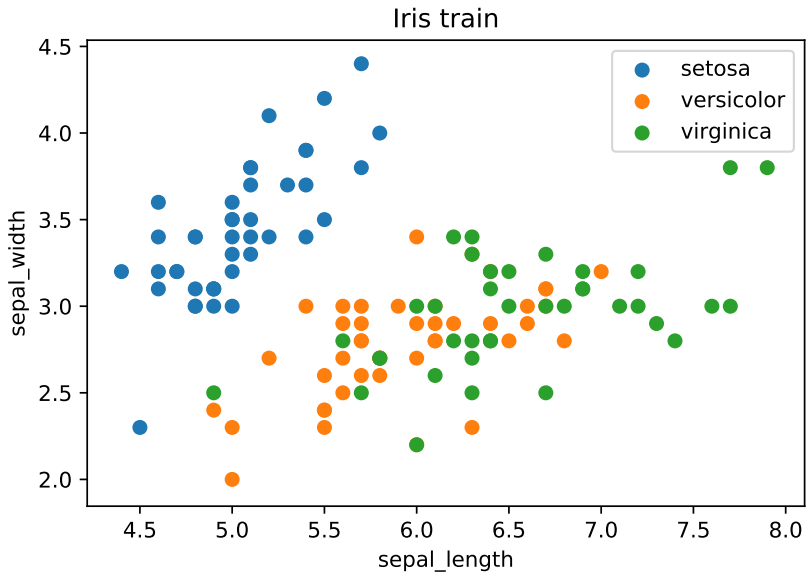

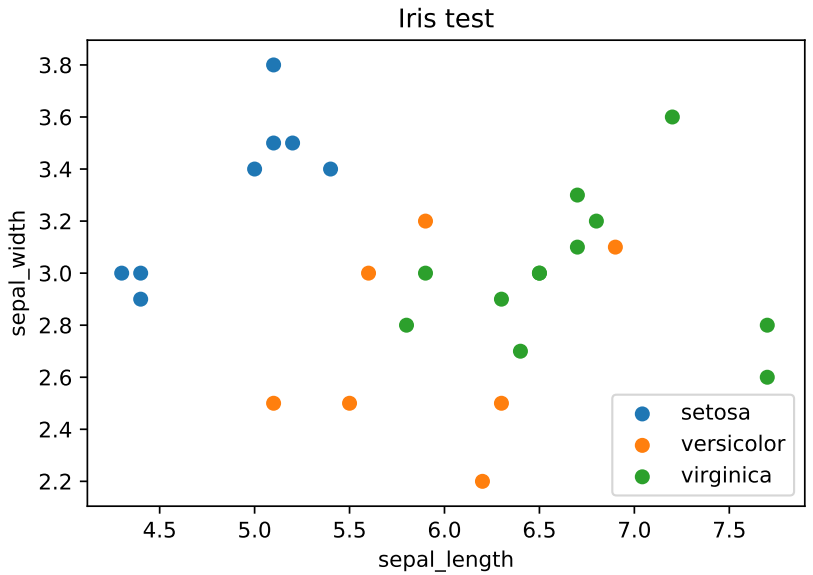

Validation (train/test)

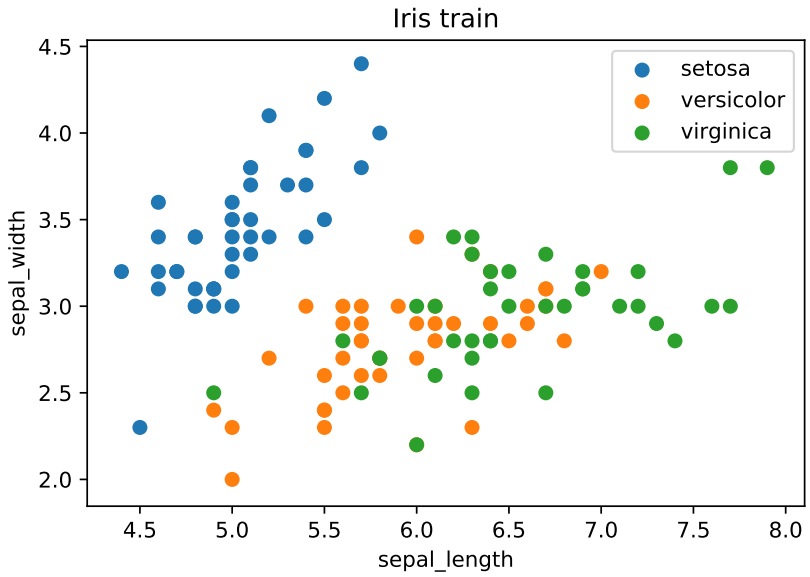

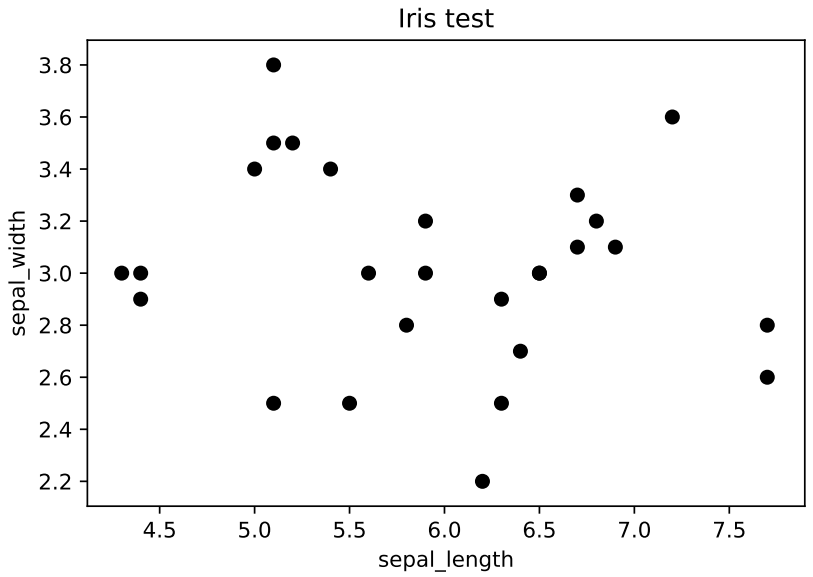

Validation (train/test)

sepal_length	sepal_width	species
5.1	3.5	setosa
4.9	3	setosa
6.7	3.1	versicolor
6.3	2.3	versicolor
6.3	2.8	virginica
6.1	2.6	virginica

Table 1: Train set

sepal_length	sepal_width	species
4.7	3.2	setosa
5.6	3	versicolor
6.7	3.3	virginica

Table 2: Test set

Validation (train/test)

sepal_length	sepal_width	species
5.1	3.5	setosa
4.9	3	setosa
6.7	3.1	versicolor
6.3	2.3	versicolor
6.3	2.8	virginica
6.1	2.6	virginica

Table 1: Train set

sepal_length	sepal_width	~~species~~
4.7	3.2	~~setosa~~
5.6	3	~~versicolor~~
6.7	3.3	~~virginica~~

Table 2: Test set

Validation (train/test)

sepal_length	sepal_width	species
5.1	3.5	setosa
4.9	3	setosa
6.7	3.1	versicolor
6.3	2.3	versicolor
6.3	2.8	virginica
6.1	2.6	virginica

Table 1: Train set

sepal_length	sepal_width	~~species~~
4.7	3.2	~~setosa~~
5.6	3	~~versicolor~~
6.7	3.3	~~virginica~~

Table 2: Test set

Objectif : prédire la classe des objets du "test set" à l'aide des données du "train set" (sans utiliser la classe des objets du "test set")

Matrice de confusion

- Matrice de comparaison entre les prédictions et la vraie classe des objets
- Permet d'évaluer les performances d'une méthode de classification
- Permet de mettre en évidence les confusions (erreurs) entre les classes

```
[[6 0 0]
 [0 9 0]
 [0 1 4]]
             precision    recall  f1-score   support

     setosa       1.00      1.00      1.00         6
 versicolor       0.90      1.00      0.95         9
  virginica       1.00      0.80      0.89         5

avg / total       0.96      0.95      0.95        20
```

Validation

sepal_length	sepal_width	species
5.1	3.5	setosa
4.7	3.2	setosa
6.7	3.1	versicolor
5.6	3	versicolor
6.3	2.8	virginica
6.7	3.3	virginica

Table 3: Ensemble de test

Validation

sepal_length	sepal_width	~~species~~
5.1	3.5	~~setosa~~
4.7	3.2	~~setosa~~
6.7	3.1	~~versicolor~~
5.6	3	~~versicolor~~
6.3	2.8	~~virginica~~
6.7	3.3	~~virginica~~

Table 3: Ensemble de test

Validation

sepal_length	sepal_width	~~species~~
5.1	3.5	~~setosa~~
4.7	3.2	~~setosa~~
6.7	3.1	~~versicolor~~
5.6	3	~~versicolor~~
6.3	2.8	~~virginica~~
6.7	3.3	~~virginica~~

Table 3: Ensemble de test

prédictions
setosa
setosa
versicolor
virginica
virginica
virginica

Table 4: Prédictions

Validation

sepal_length	sepal_width	~~species~~
5.1	3.5	~~setosa~~
4.7	3.2	~~setosa~~
6.7	3.1	~~versicolor~~
5.6	3	~~versicolor~~
6.3	2.8	~~virginica~~
6.7	3.3	~~virginica~~

Table 3: Ensemble de test

prédictions
setosa
setosa
versicolor
virginica
virginica
virginica

Table 4: Prédictions

	setosa	versicolor	virginica
setosa	0	0	0
versicolor	0	0	0
virginica	0	0	0

Table 5: Matrice de confusion

Validation

sepal_length	sepal_width	species
5.1	3.5	setosa
4.7	3.2	setosa
6.7	3.1	versicolor
5.6	3	versicolor
6.3	2.8	virginica
6.7	3.3	virginica

Table 3: Ensemble de test

prédictions
setosa
setosa
versicolor
virginica
virginica
virginica

Table 4: Prédictions

	setosa	versicolor	virginica
setosa	1	0	0
versicolor	0	0	0
virginica	0	0	0

Table 5: Matrice de confusion

Validation

sepal_length	sepal_width	species
5.1	3.5	setosa
4.7	3.2	setosa
6.7	3.1	versicolor
5.6	3	versicolor
6.3	2.8	virginica
6.7	3.3	virginica

Table 3: Ensemble de test

prédictions
setosa
setosa
versicolor
virginica
virginica
virginica

Table 4: Prédictions

	setosa	versicolor	virginica
setosa	2	0	0
versicolor	0	0	0
virginica	0	0	0

Table 5: Matrice de confusion

Validation

sepal_length	sepal_width	species
5.1	3.5	setosa
4.7	3.2	setosa
6.7	3.1	versicolor
5.6	3	versicolor
6.3	2.8	virginica
6.7	3.3	virginica

Table 3: Ensemble de test

prédictions
setosa
setosa
versicolor
virginica
virginica
virginica

Table 4: Prédictions

	setosa	versicolor	virginica
setosa	2	0	0
versicolor	0	1	0
virginica	0	0	0

Table 5: Matrice de confusion

Validation

sepal_length	sepal_width	species
5.1	3.5	setosa
4.7	3.2	setosa
6.7	3.1	versicolor
5.6	3	versicolor
6.3	2.8	virginica
6.7	3.3	virginica

Table 3: Ensemble de test

prédictions
setosa
setosa
versicolor
virginica
virginica
virginica

Table 4: Prédictions

	setosa	versicolor	virginica
setosa	2	0	0
versicolor	0	1	1
virginica	0	0	0

Table 5: Matrice de confusion

Erreur de classification

Validation

sepal_length	sepal_width	species
5.1	3.5	setosa
4.7	3.2	setosa
6.7	3.1	versicolor
5.6	3	versicolor
6.3	2.8	virginica
6.7	3.3	virginica

Table 3: Ensemble de test

prédictions
setosa
setosa
versicolor
virginica
virginica
virginica

Table 4: Prédictions

	setosa	versicolor	virginica
setosa	2	0	0
versicolor	0	1	1
virginica	0	0	2

Table 5: Matrice de confusion

Validation

sepal_length	sepal_width	species
5.1	3.5	setosa
4.7	3.2	setosa
6.7	3.1	versicolor
5.6	3	versicolor
6.3	2.8	virginica
6.7	3.3	virginica

Table 3: Ensemble de test

prédictions
setosa
setosa
versicolor
virginica
virginica
virginica

Table 4: Prédictions

	setosa	versicolor	virginica
setosa	2	0	0
versicolor	0	1	1
virginica	0	0	2

Table 5: Matrice de confusion

Bonnes prédictions (diagonale) $= 2 + 1 + 2$

Mauvaise prédiction (hors diagonale) $= 1$

Précision $= \frac{2+1+2}{2+1+2+1} = 0.83$

Validation croisée (cross validation)

- Alternative au découpage train / test
- Le jeu de données est coupé en K sous ensembles
- K-1 ensembles utilisés pour le train, 1 ensemble utilisé pour le test
- Chaque ensemble est utilisé une fois pour le test

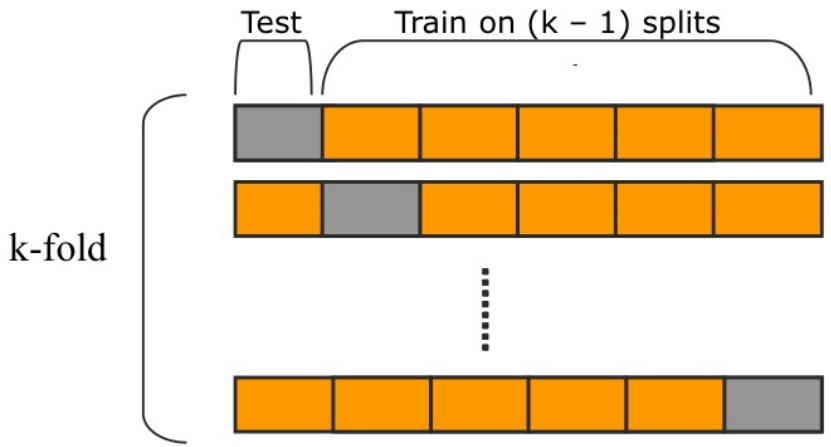

source : https://raw.githubusercontent.com/qingkaikong/

Scikit-learn

Scikit-learn

- Scikit-learn contient la majorité des algorithmes de fouille de données
- Il offre également de nombreux outils pour l'évaluation des modèles
- Scikit-learn décompose les données et la variable à prédire (*target*)

```
1 from sklearn.model_selection import train_test_split
2
3 df = pd.read_csv('data/iris.csv', header=0)
4 X = df[['sepal_length','sepal_width','petal_length','petal_width']]
5 y = df[['species']]
6
7 X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2)
```

Scikit-learn

- Scikit-learn décompose les données et la variable à prédire (*target*)

sepal_length	sepal_width	species
5.1	3.5	setosa
4.9	3	setosa
6.7	3.1	versicolor
6.3	2.3	versicolor
6.3	2.8	virginica
6.1	2.6	virginica

Table 6: Train set

sepal_length	sepal_width	species
4.7	3.2	setosa
5.6	3	versicolor
6.7	3.3	virginica

Table 7: Test set

Scikit-learn

- Scikit-learn décompose les données et la variable à prédire (*target*)

X_train		y_train
sepal_length	sepal_width	species
5.1	3.5	setosa
4.9	3	setosa
6.7	3.1	versicolor
6.3	2.3	versicolor
6.3	2.8	virginica
6.1	2.6	virginica

Table 8: Train set

X_test		y_test
sepal_length	sepal_width	species
4.7	3.2	setosa
5.6	3	versicolor
6.7	3.3	virginica

Table 9: Test set

Scikit-learn

- Scikit-learn permet également de calculer la matrice de confusion et d'évaluer les performances des modèles

```
1 from sklearn.metrics import confusion_matrix, classification_report,
      precision_score
2
3 real = ['setosa','setosa','versicolor','versicolor','virginica','virginica']
4 pred = ['setosa','setosa','versicolor','virginica','virginica','virginica']
5
6 print(confusion_matrix(real, pred))
7 print(classification_report(real , pred))
8 print(precision_score(real , pred, average='micro'))
```

```
                              precision    recall  f1-score   support

[[2 0 0]                        setosa       1.00      1.00      1.00         2
 [0 1 1]                    versicolor       1.00      0.50      0.67         2
 [0 0 2]]                    virginica       0.67      1.00      0.80         2

0.8333333333333334             accuracy                           0.83         6
                               macro avg       0.89      0.83      0.82         6
                            weighted avg       0.89      0.83      0.82         6
```

Un premier classifieur

Un premier classifieur

Exercice

- A l'aider de la visualisation de données du jeu de données Iris, créer un classifieur simple à base de seuils afin de classer les différents types d'iris
- Évaluer les performances de votre classifieur sur toutes les données
- Faire un graphique pour illustrer la frontière des classes

```
1 import pandas as pd
2 from sklearn.metrics import confusion_matrix
3 from sklearn.metrics import classification_report
4
5 # lecture des données
6 df = pd.read_csv('data/iris.csv', header=0)
7
8 # écrire un classifieur à base de seuils
```

Corrigé

```
1  import pandas as pd
2  from sklearn.metrics import confusion_matrix
3  from sklearn.metrics import classification_report
4
5  # lecture des données
6  df = pd.read_csv('data/iris.csv', header=0)
7
8  df['pred'] = 'setosa'
9  df.loc[df['petal_width'] > 0.8,'pred'] = 'versicolor'
10 df.loc[df['petal_width'] > 1.7,'pred'] = 'virginica'
11
12 print(confusion_matrix(df['pred'] , df['species']))
13 print(classification_report(df['pred'] , df['species']))
```

Corrigé

```
import pandas as pd
import matplotlib.pyplot as plt

df = pd.read_csv('data/iris.csv', header=0)
groups = df.groupby('species')

fig, ax = plt.subplots()
ax.margins(0.05)
for name, group in groups:
    ax.plot(group.petal_length, group.petal_width, marker='o', linestyle='', ms
     =4, label=name)
plt.xlabel("petal_length")
plt.ylabel("petal_width")
plt.title("Iris dataset")
plt.axhline(0.8)
plt.axhline(1.7)
ax.legend()
plt.show()
```

Corrigé

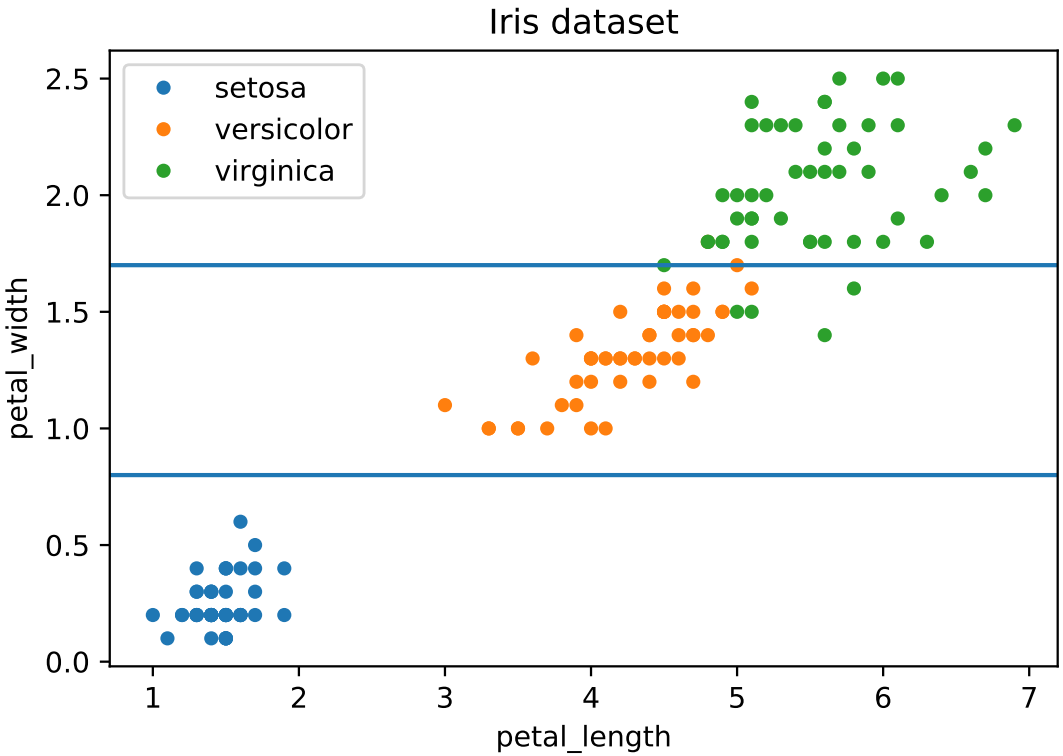
Iris dataset
setosa
versicolor
virginica
petal_width
petal_length
0.0
0.5
1.0
1.5
2.0
2.5
1
2
3
4
5
6
7